# 知页 LOCALFOLIO

04 端侧 AI 推理性能优化与 seekdb 混合检索 | 一页技术说明 | 2026-10-28

## 01 完整链路与正确性

TXT/MD → 500 字符分块（重叠 60）→ 浏览器 Worker 向量化 → seekdb-js upsert + refresh_index → 数据库内全文/HNSW/RRF → 带出处的结果。文档与查询都在浏览器计算；服务端关闭自动 embedding，不在客户端拼接两路结果。哈希 ID 保证重复导入幂等，集合指纹隔离会话和精度。

## 02 固定模型与运行环境

Xenova/multilingual-e5-small，384 维、mean pooling、归一化，使用 query:/passage: 前缀。revision: 761b726dd34fb83930e26aab4e9ac3899aa1fa78

ONNX 权重：FP32 470,268,533 字节 → INT8 118,308,185 字节；压缩 3.975 倍，减少 74.84%。共享 tokenizer/config 另计；逐文件 SHA-256 在原始 JSON。

Ryzen 9 7945HX / 32 线程，15.69 GiB RAM，RTX 4060 Laptop；Windows / Edge 156 无头独立会话。WSL2 Ubuntu 24.04 + seekdb 1.4.0.0；Node 22.20.0、seekdb-js 1.4.0、Transformers.js 3.8.1；WASM 单线程。

## 03 真实测量：质量与性能

生产构建，12 份人工公开示例、6 条标签查询。每配置 3 次语料向量化、3 轮查询，中位数计时；每配置使用独立数据库集合。

| 配置 | 实际后端 | 分块/秒 | 端到端 ms | Recall@5 | nDCG@5 |
|---|---|---|---|---|---|
| FP32 / batch 1 | WASM | 16.67 | 75.75 | 0.8333 | 0.7891 |
| INT8 / batch 1 | WASM | 18.63 | 68.25 | 0.8333 | 0.7962 |
| INT8 / batch 8 | WASM | 17.47 | 68.20 | 0.8333 | 0.7962 |
| INT8 / 自动 / batch 8 | WASM 回退 | 24.47 | 66.55 | 0.8333 | 0.7962 |

同 batch 1：INT8 吞吐提高 11.8%，查询中位数下降 9.9%；该样例集质量未下降。batch 8 没有稳定收益，交互默认 batch 1。

## 04 后端降级、计时口径与复现

优先尝试 WebGPU；初始化/执行失败或 3 个公开句子的 GPU/WASM 最小余弦低于 0.99 时回退。本机初始未检查的 GPU 实验 nDCG 降至 0.5509，最终检测并回退 WASM，不宣称 GPU 加速。自动配置吞吐还受预热及顺序影响。数值检查不代替标签评估。

新浏览器上下文 INT8/WASM 初始化 1.425 秒，热查询另计；OS 文件缓存可能已热。表中端到端含 Worker/API 往返，不含绘制；写入、刷新和交互绘制近似计时保留在 JSON。小样例结果不能代表大规模质量。

通过：基础测试 4/4、生产构建、真实数据库检查、Edge 完整流程与 390px 布局检查；测试会话无外网 HTTP 请求。复现：npm test；npm run build；npm run test:db；npm run test:browser -- --benchmark。

证据：results/benchmark.json、results/verification.json、results/initial-webgpu-unchecked.json；模型与包版本见锁文件和 manifest，详细启动说明见 README.md。